


# Binary Cross Entropy




L: loss값은 예측값과 실제값이 비슷하다면 Loss는 0에 비슷해지고


loss값이 예측값과 실제값이 비슷하지 않다면 loss는 무한대로 발산한다.

Ex)

$y = 1$ 이라고 가정하고 모델 예측값이 0이면은 Loss값은 무한대로 발산하고 반대로 예측값이 1이면은 Loss값은 0으로 수렴한다.



- $-\log$  그래프는 위 처럼 생겼다. 우리의 예측값은 0 ~ 1 사이에 존재하는데 예측값이 1에 가까워질 수록 0에 가까워지고 반대로 예측값이 0에 가까워지면 무한대로 발산한다.



- 실제값이 0일때는 예측값이 0으로 예측하면 loss는 0으로 수렴을하고 반대로 예측값이 1이면은 loss는 1로 발산하게 된다. 그래서 그래프를 그려보면  $-\log x$  그래프의 대칭인  $-\log(1-x)$  그래프를 그려지는걸 볼 수 있다.

$$H_b(y, \hat{y}) = - [y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})]$$

$$y=1 \Rightarrow L = -\log(\hat{y})$$

$$y=0 \Rightarrow L = -\log(1-\hat{y})$$

- 그래서 실제값이 1일때는 Loss의 형태는  $-\log(y^{\wedge})$ 값이되고 실제값이 0일 때는 Loss의 형태는  $-\log(1-y^{\wedge})$ 형태로 나온다

### - Binary Cross Entropy


$$H_b(y, \hat{y}) = - [\overset{1}{y} \log(\hat{y}) + \cancel{(1-y)} \log(1-\hat{y})]$$

$$y=1 \Rightarrow -\log(\hat{y})$$


$$H_b(y, \hat{y}) = - [\cancel{y \log(\hat{y})} + (1 - \cancel{y}) \log(1 - \hat{y})]$$

$y=0$       $L = -\log(1 - \hat{y})$

$$H_b(y, \hat{y}) = - [y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})]$$




- 그래서 위 식은  $y$ 가 0일때 1일때 모두 사용할 수 있는 식이된다.



- 데이터 안에는 0, 1만들어 있음 그리하여 아웃풋은 결과는 0과 1사이의 값인 확률로 가지게 된다.
- x 데이터가 dense layer을 통과하면서  $\hat{y}$ 가 나오는걸 볼 수 있는데 자세히 보면  $\hat{y}$ 은 확률 값이다. 확률값이 나온다. 그래서 우리는 마지막 layer에 activation function을 넣어주는거다.
- 그래서 우리는 sigmoid를 통과한 값들을 Binary Cross Entropy에 넣을 수 있게 되는 것이다.
- 그래서 우리는 뉴럴 네트워크를 만들 때 예를들어 고양이와 강아지를 분류하는 모델을 만들 때 마지막 output layer에는 sigmoid를 사용하면서 probability를 출력을 하게 되는거고 이것을 가지고 Loss값을 구하게 되는것이다.

## Minibatch일 때 Binary Cross Entropy형태



- 데이터를 미니배치형태로 넣을 때는 각각의 loss를 평균을 낸다고 생각하면 된다.